



Συγκριτική Αξιολόγηση Μοντέλων Μείωσης Διάστασης και Συσταδοποίησης στο Σύνολο Δεδομένων Fashion-MNIST

Ζερβάκη Άννα

AM: ics21122

Μηχανική Μάθηση

Ακαδημαϊκό έτος: 2025-2026

Περιεχόμενα

1. Εισαγωγή

1.1 Το Σύνολο Δεδομένων και η Διαχείρισή τους

1.2 Σκοπός και Μεθοδολογία

2. Μεθοδολογία

2.1 Προεπεξεργασία και Προετοιμασία Δεδομένων

2.2 Υλοποίηση Stacked Autoencoder (SAE)

2.3 Λοιπές Τεχνικές Μείωσης Διάστασης

2.4 Διαδικασία Συσταδοποίησης και Αξιολόγησης

3. Ανάλυση Αποτελεσμάτων και Συγκριτική Αξιολόγηση

3.1 Επίδραση στη Χρονική Πολυπλοκότητα

3.2 Ποιότητα Συσταδοποίησης και Δείκτης Silhouette

3.3 Η Αποτυχία του Αλγορίθμου DBSCAN

3.4 Αντιστοίχιση με Πραγματικές Κλάσεις (ARI)

3.5 Οπτικοποίηση Δειγμάτων Συσταδοποίησης

4. Συμπεράσματα

5. Βιβλιογραφία

1. Εισαγωγή

Αντικείμενο της παρούσας εργαστηριακής άσκησης αποτελεί η μελέτη και η συγκριτική αξιολόγηση διαφορετικών συνδυαστικών μοντέλων Μείωσης Διάστασης (Dimensionality Reduction) και Συσταδοποίησης (Clustering) πάνω σε δεδομένα εικόνας. Στόχος είναι να διερευνηθεί πώς η μετάβαση από τον αρχικό χώρο των μεταβλητών (raw pixel data) σε έναν χώρο χαμηλότερης διάστασης επηρεάζει την ποιότητα της ομαδοποίησης και την υπολογιστική ισχύ που απαιτείται.

1.1 Το Σύνολο Δεδομένων και η Διαχείρισή τους

Για την υλοποίηση των πειραμάτων χρησιμοποιήθηκε το σύνολο δεδομένων Fashion-MNIST, το οποίο αποτελείται από 70.000 εικόνες κλίμακας του γκρι, μεγέθους 28×28 pixels, καταμετρημένες σε 10 κατηγορίες ενδυμάτων και υποδημάτων.

Για τις ανάγκες της άσκησης, τα δεδομένα χωρίστηκαν σε τρία διακριτά σύνολα: εκπαίδευσης (train), επαλήθευσης (validation) και ελέγχου (test). Η εκπαίδευση των μοντέλων μείωσης διάστασης πραγματοποιήθηκε στο σύνολο εκπαίδευσης, ενώ η τελική εφαρμογή των αλγορίθμων συσταδοποίησης έγινε αποκλειστικά στο σύνολο ελέγχου (test set). Η επιλογή αυτή βασίστηκε στο γεγονός ότι το test set είναι σημαντικά μικρότερο σε πλήθος παρατηρήσεων, επιτρέποντας την ταχύτερη εκτέλεση των αλγορίθμων συσταδοποίησης και την αποτελεσματικότερη αξιολόγηση των μοντέλων.

1.2 Σκοπός και Μεθοδολογία

Η αξιολόγηση βασίστηκε στη σύγκριση τριών (3) τεχνικών μείωσης διάστασης:

1. Principal Component Analysis (PCA): Μια γραμμική τεχνική που στοχεύει στη διατήρηση της μέγιστης διακύμανσης των δεδομένων.
2. Stacked Autoencoder (SAE): Ένα βαθύ νευρωνικό δίκτυο (Neural Network) που μαθαίνει μια μη γραμμική αναπαράσταση των δεδομένων.
3. Truncated SVD: Μια τεχνική παρόμοια με την PCA, η οποία είναι ιδιαίτερα αποδοτική στην επεξεργασία πινάκων υψηλής διάστασης.

Οι παραπάνω τεχνικές συνδυάστηκαν με τρεις αλγορίθμους συσταδοποίησης: MiniBatchKMeans, DBSCAN και Gaussian Mixture Models (GMM). Η απόδοση των συνδυασμών μετρήθηκε με βάση τη συνοχή και τον διαχωρισμό των συστάδων, χρησιμοποιώντας τέσσερις δείκτες: Silhouette Score, Davies–Bouldin index, Calinski–Harabasz index και Adjusted Rand Index (ARI).

2. Μεθοδολογία

2.1 Προεπεξεργασία και Προετοιμασία Δεδομένων

Πριν την εφαρμογή των μοντέλων, τα δεδομένα υποβλήθηκαν σε τρία βασικά στάδια επεξεργασίας:

1. Κανονικοποίηση (Normalization): Οι τιμές των pixels μετατράπηκαν από το διάστημα $[0, 255]$ στο διάστημα $[0, 1]$, διαιρώντας με το 255. Η κίνηση αυτή είναι απαραίτητη για τη σταθερότητα και την ταχύτερη σύγκλιση των νευρωνικών δικτύων.
2. Επιπεδοποίηση (Flattening): Οι δισδιάστατες εικόνες (28×28) μετατράπηκαν σε μονοδιάστατα διανύσματα 784 στοιχείων, ώστε να είναι συμβατές με τους αλγορίθμους PCA και SVD, καθώς και με τα Dense layers του Autoencoder.
3. Διαχωρισμός Δεδομένων: Τα δεδομένα χωρίστηκαν σε Train (48.000 δείγματα), Validation (12.000 δείγματα) και Test (10.000 δείγματα).

2.2 Υλοποίηση Stacked Autoencoder (SAE)


Η αρχιτεκτονική του Stacked Autoencoder σχεδιάστηκε με στόχο τη σταδιακή συμπίεση της πληροφορίας σε έναν χώρο χαμηλής διάστασης (32 χαρακτηριστικά).

Encoder (Κωδικοποιητής): Αποτελείται από τρία πλήρως συνδεδεμένα επίπεδα (Dense Layers) με 128, 64 και 32 νευρώνες αντίστοιχα. Χρησιμοποιήθηκε η συνάρτηση ενεργοποίησης ReLU. Σύμφωνα με τις απαιτήσεις της άσκησης, μετά την εκπαίδευση, το κομμάτι αυτό απομονώθηκε για να παράγει τα κωδικοποιημένα χαρακτηριστικά (embeddings) του test set.

Decoder (Αποκωδικοποιητής): Ακολουθεί την αντίστροφη πορεία ($64 \rightarrow 128 \rightarrow 784$) για την ανακατασκευή της αρχικής εικόνας. Στο τελευταίο επίπεδο χρησιμοποιήθηκε η συνάρτηση Sigmoid, ώστε οι έξοδοι να κυμαίνονται στο διάστημα $[0, 1]$.

Εκπαίδευση: Το μοντέλο εκπαιδεύτηκε για 15 εποχές (epochs) με μέγεθος παρτίδας (batch size) 256. Κατά τη διάρκεια του fit


χρησιμοποιήθηκαν τα validation data για την παρακολούθηση της απώλειας (MSE loss) και την αποφυγή υπερπροσαρμογής (overfitting).



Σχήμα 1: Αποτελέσματα ανακατασκευής εικόνων από τον Stacked Autoencoder. Η ομοιότητα μεταξύ πρωτότυπων (Original) και ανακατασκευασμένων εικόνων (SAE Rec) επιβεβαιώνει την επιτυχή εκπαίδευση του μοντέλου.

2.3 Λοιπές Τεχνικές Μείωσης Διάστασης

PCA: Ρυθμίστηκε ώστε να διατηρεί το 95% της διακύμανσης των δεδομένων, επιτυγχάνοντας σημαντική μείωση του θορύβου.



Σχήμα 2: Οπτική αναπαράσταση της μείωσης διάστασης μέσω PCA. Παρά τη μείωση του χώρου των μεταβλητών, οι ανακατασκευασμένες εικόνες διατηρούν τα κύρια χαρακτηριστικά των αντικειμένων.

Truncated SVD: Εφαρμόστηκε με σταθερό αριθμό συνιστωσών ($n_components=50$), παρέχοντας μια εναλλακτική γραμμική προσέγγιση συμπίεσης.

2.4 Διαδικασία Συσταδοποίησης και Αξιολόγησης

Οι τρεις αλγόριθμοι clustering (MiniBatchKMeans, DBSCAN, GMM) εφαρμόστηκαν διαδοχικά σε τέσσερις εκδοχές των δεδομένων: στα αρχικά (Raw) και στα χαρακτηριστικά που προέκυψαν από τις τρεις παραπάνω τεχνικές.

Για την αξιολόγηση χρησιμοποιήθηκαν:

Silhouette Score: Μέτρηση του πόσο παρόμοιο είναι ένα αντικείμενο με τη δική του συστάδα σε σύγκριση με άλλες.

Davies–Bouldin Index: Μέτρηση του μέσου όρου ομοιότητας μεταξύ των συστάδων (χαμηλότερες τιμές υποδεικνύουν καλύτερο διαχωρισμό).

Calinski–Harabasz Index: Λόγος της διασποράς μεταξύ των συστάδων προς τη διασπορά εντός των συστάδων.

Adjusted Rand Index (ARI): Σύγκριση των αποτελεσμάτων με τις πραγματικές ετικέτες (labels) του Fashion-MNIST.

3. Ανάλυση Αποτελεσμάτων και Συγκριτική Αξιολόγηση

Τα αποτελέσματα των πειραμάτων, όπως καταγράφηκαν στον συγκεντρωτικό πίνακα, αναδεικνύουν σημαντικές διαφορές στην απόδοση των αλγορίθμων ανάλογα με την τεχνική μείωσης διάστασης που προηγήθηκε.


Dim. Red. Technique	Clustering Algorithm	Training Time (s)	Execution Time (s)	Suggested Clusters	Calinski-Harabasz	Davies-Bouldin	Silhouette	Adjusted Rand Index
Raw	MiniBatchK Means	0.0000	0.3327	10	1240.0751	1.9861	0.1385	0.3173
Raw	DBSCAN	0.0000	18.7861	0	0.0000	0.0000	0.0000	0.0000
Raw	GMM	0.0000	407.7094	10	1031.4783	2.0628	0.1206	0.3346
PCA	MiniBatchK Means	0.7950	0.0446	10	1374.3905	1.9513	0.1417	0.3282
PCA	DBSCAN	0.7950	1.5155	0	0.0000	0.0000	0.0000	0.0000
PCA	GMM	0.7950	38.3155	10	967.8123	2.3991	0.1047	0.3731
SAE	MiniBatchK Means	66.3626	0.0231	10	2484.2488	1.4849	0.2108	0.2944

SAE	DBSCAN	66.3626	0.4740	0	0.0000	0.0000	0.0000	0.0000
SAE	GMM	66.3626	7.3284	10	957.5917	2.3968	0.0810	0.3231
TruncatedSVD	MiniBatchKMeans	4.7538	0.0148	10	1659.9308	1.8814	0.1652	0.2877
TruncatedSVD	DBSCAN	4.7538	0.6053	0	0.0000	0.0000	0.0000	0.0000
TruncatedSVD	GMM	4.7538	10.3079	10	1093.9250	2.5986	0.1253	0.4193

Πίνακας 1. Συγκεντρωτικά αποτελέσματα μετρήσεων για όλους τους συνδυασμούς τεχνικών.

3.1 Επίδραση στη Χρονική Πολυπλοκότητα


Η πρώτη και πιο εμφανής παρατήρηση αφορά τη δραστική μείωση του χρόνου εκτέλεσης (Execution Time). Ενώ ο αλγόριθμος GMM (Gaussian Mixture Models) απαίτησε περισσότερα από 400 δευτερόλεπτα για να επεξεργαστεί τα ακατέργαστα (Raw) δεδομένα, ο χρόνος αυτός μειώθηκε σε μόλις 7,3 δευτερόλεπτα μετά την εφαρμογή του Stacked Autoencoder (SAE) και σε 10,3 δευτερόλεπτα με το TruncatedSVD. Η μείωση της διάστασης από τις 784 μεταβλητές σε μόλις 32 ή 50, επέτρεψε στους αλγόριθμους να συγκλίνουν πολύ ταχύτερα, καθιστώντας τη διαδικασία υπολογιστικά βιώσιμη.



Σχήμα 3. Σύγκριση χρόνου εκτέλεσης σε λογαριθμική κλίμακα. Είναι εμφανής η δραστική επιτάχυνση των αλγορίθμων μετά τη μείωση διάστασης.

3.2 Ποιότητα Συσταδοποίησης και Δείκτης Silhouette

Σύμφωνα με το γράφημα σύγκρισης του δείκτη Silhouette, ο συνδυασμός SAE + MiniBatchKMeans πέτυχε την υψηλότερη επίδοση με τιμή 0,2108. Η υπεροχή του Autoencoder έναντι του PCA (0,1417) και των Raw δεδομένων (0,1385) οφείλεται στην ικανότητα των νευρωνικών δικτύων να εντοπίζουν μη γραμμικές σχέσεις στα δεδομένα. Ο SAE λειτούργησε ως ένα ισχυρό "φίλτρο" που αφαίρεσε τον θόρυβο των pixels, κρατώντας μόνο τα ουσιώδη χαρακτηριστικά των ενδυμάτων, γεγονός που αποτυπώνεται και στον δείκτη Davies-Bouldin, όπου ο SAE σημείωσε την ελάχιστη (βέλτιστη) τιμή 1,4849.



Σχήμα 4. Σύγκριση του δείκτη Silhouette. Ο συνδυασμός SAE + MiniBatchKMeans παρουσιάζει την υψηλότερη τιμή, υποδεικνύοντας πιο συμπαγείς συστάδες.

3.3 Η Αποτυχία του Αλγορίθμου DBSCAN

Ένα ιδιαίτερο εύρημα της μελέτης είναι η πλήρης αδυναμία του DBSCAN να εντοπίσει συστάδες, επιστρέφοντας μηδενικά αποτελέσματα σε όλες τις δοκιμές. Αυτό εξηγείται από τη φύση του Fashion-MNIST, όπου οι εικόνες διαφορετικών κλάσεων (π.χ. Shirt και Coat) συχνά επικαλύπτονται στον πολυδιάστατο χώρο. Ο DBSCAN, ως αλγόριθμος βασισμένος στην πυκνότητα, απαιτεί πολύ ακριβή ρύθμιση της παραμέτρου ϵ για να διακρίνει τα όρια μεταξύ των ομάδων, κάτι που καθίσταται εξαιρετικά δύσκολο σε δεδομένα τόσο υψηλής πολυπλοκότητας.

3.4 Αντιστοίχιση με Πραγματικές Κλάσεις (ARI)

Παρόλο που ο SAE κυριάρχησε στις μετρικές εσωτερικής συνοχής, ο αλγόριθμος GMM σε συνδυασμό με το TruncatedSVD παρουσίασε το υψηλότερο Adjusted Rand Index (ARI) με τιμή 0,4193. Αυτό υποδηλώνει ότι ο συγκεκριμένος συνδυασμός κατάφερε να ομαδοποιήσει τις εικόνες με τρόπο που πλησιάζει περισσότερο τις πραγματικές κατηγορίες των δεδομένων, παρά το γεγονός ότι οι συστάδες του ήταν λιγότερο "συμπαγείς" σε σχέση με αυτές του SAE.

3.5 Οπτικοποίηση Δειγμάτων Συσταδοποίησης

Για την οπτική επιβεβαίωση της ποιότητας των αποτελεσμάτων, παρατίθενται τυχαία δείγματα από τέσσερις επιλεγμένες συστάδες του βέλτιστου συνδυασμού (SAE + MiniBatchKMeans). Όπως παρατηρείται στο Σχήμα 5, κάθε σειρά αντιστοιχεί σε μια διακριτή συστάδα, παρουσιάζοντας υψηλά επίπεδα ομοιογένειας. Συγκεκριμένα, η πρώτη σειρά περιλαμβάνει αποκλειστικά αθλητικά υποδήματα, η δεύτερη μπλούζες και κοντομάνικα ενδύματα, η τρίτη γυναικεία πέδιλα, ενώ η τέταρτη αποτελείται από πανωφόρια και τζάκετ.

Αυτή η καθαρή οπτική κατηγοριοποίηση εξηγεί την υπεροχή του συγκεκριμένου συνδυασμού στις μετρικές εσωτερικής συνοχής, καθώς πέτυχε την υψηλότερη τιμή Silhouette (0,2108) και τον βέλτιστο δείκτη Calinski-Harabasz (2484,25). Τα αποτελέσματα επιβεβαιώνουν ότι ο Stacked Autoencoder λειτούργησε αποτελεσματικά ως μηχανισμός εξαγωγής χαρακτηριστικών, επιτρέποντας τον διαχωρισμό των κλάσεων στον χώρο των 32 διαστάσεων με τρόπο που ανταποκρίνεται στη λογική δομή του συνόλου δεδομένων Fashion-MNIST.



Σχήμα 5. Ενδεικτικά αποτελέσματα ομαδοποίησης. Παρατηρείται ότι ο αλγόριθμος πέτυχε υψηλή ομοιογένεια εντός των συστάδων (π.χ. διαχωρισμός υποδημάτων από ενδύματα).

4. Συμπεράσματα

Συνοψίζοντας τα ευρήματα της παρούσας εργαστηριακής άσκησης, προκύπτει το συμπέρασμα ότι η επιλογή της βέλτιστης μεθοδολογίας είναι άρρηκτα συνδεδεμένη με τις προτεραιότητες της εκάστοτε ανάλυσης, καθώς δεν εντοπίστηκε ένας μοναδικός συνδυασμός που να υπερέχει καθολικά σε όλες τις μετρικές αξιολόγησης. Στην περίπτωση που ο πρωταρχικός στόχος είναι η επίτευξη μέγιστης εσωτερικής συνοχής και ο σαφής διαχωρισμός των συστάδων, ο συνδυασμός του Stacked Autoencoder με τον αλγόριθμο MiniBatchKMeans αναδεικνύεται ως η κορυφαία επιλογή, γεγονός που υπογραμμίζει την αποτελεσματικότητα των μη γραμμικών αναπαραστάσεων στην επεξεργασία σύνθετων δεδομένων εικόνας.

Από την άλλη πλευρά, αν η προτεραιότητα έγκειται στην ακριβή αντιστοίχιση των συστάδων με τις πραγματικές κατηγορίες του Fashion-MNIST, ο συνδυασμός του TruncatedSVD με το μοντέλο Gaussian Mixture (GMM) αποδείχθηκε πιο αποδοτικός, επιτυγχάνοντας την υψηλότερη τιμή στον δείκτη Adjusted Rand Index. Επιπλέον, η

έρευνα ανέδειξε την καθοριστική σημασία της μείωσης διάστασης στην υπολογιστική ισχύ, καθώς η μετάβαση από τον αρχικό χώρο των μεταβλητών σε συμπιεσμένες αναπαραστάσεις οδήγησε σε δραστική μείωση του χρόνου εκτέλεσης, καθιστώντας αλγορίθμους όπως ο GMM πρακτικά εφαρμόσιμους.

Συμπερασματικά, ο Stacked Autoencoder προτείνεται ως η πλέον ολοκληρωμένη λύση για το συγκεκριμένο dataset, καθώς λειτούργησε αποτελεσματικά ως μηχανισμός εξαγωγής χαρακτηριστικών, επιτρέποντας τον διαχωρισμό των κλάσεων στον χώρο των 32 διαστάσεων με τρόπο που ανταποκρίνεται στη λογική δομή του συνόλου δεδομένων Fashion-MNIST.

5.Σχετική Βιβλιογραφία

Xiao, H., Rasul, K., & Vollgraf, R. (2017). *Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms*. arXiv preprint arXiv:1708.07747.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.

Rousseeuw, P. J. (1987). *Silhouettes: A graphical aid to the interpretation and validation of cluster analysis*. Journal of Computational and Applied Mathematics, 20, 53-65.

Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996, August). *A density-based algorithm for discovering clusters in large spatial databases with noise*. In KDD (Vol. 96, No. 34, pp. 226-231).